

Apprentissage Supervisé

Dr Seydou Nourou SYLLA

Université Alioune DIOP de Bambey
Master Système d'Information & Systèmes Réseaux

2 mars 2026

Plan général du cours

- 1 Objectifs et positionnement
- 2 Exemples d'applications
- 3 Rappels fondamentaux

Rappel : Classification $\rightarrow$ variable cible **catégorielle** ; Régression $\rightarrow$ variable cible **continue**.


Pourquoi l'apprentissage supervisé ?

Contexte :

- Volumes de données croissants dans de nombreux domaines
- Les règles explicites atteignent leurs limites → apprentissage à partir des données
- Exemples : classification (spam, diagnostic), régression (prévision, scoring)

Ce que vous saurez faire :

- Comprendre et implémenter les algorithmes clés
- Choisir le bon modèle selon le contexte
- Évaluer rigoureusement les performances



Définition

L'apprentissage supervisé consiste à apprendre une fonction $f : \mathcal{X} \rightarrow \mathcal{Y}$ à partir d'un ensemble d'exemples **étiquetés** :

$$\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

où $x_i \in \mathbb{R}^p$ est le vecteur de caractéristiques et y_i est l'étiquette.


Classification ($y_i \in \{0, 1, \dots, K\}$)

- Détection d'intrusion (normal / attaque)
- Spam / Ham
- Diagnostic médical

Régression ($y_i \in \mathbb{R}$)

- Prédiction de bande passante
- Estimation de charge serveur
- QoS prévisionnelle

Pipeline d'apprentissage supervisé



Exemple de modèles

Modèle	Type	Paradigme
KNN	Paresseux (lazy)	Similarité / voisinage
Arbre de décision	Symbolique	Partitionnement
Random Forest	Ensemble	Bagging
Gradient Boosting	Ensemble	Boosting
Régression logistique	Linéaire	Probabiliste
SVM	Linéaire / noyau	Marge maximale
Naïve Bayes	Probabiliste	Indépendance des features
Régression linéaire	Linéaire	Moindres carrés
MLP	Réseau de neurones	Descente de gradient

Classification et régression : le choix du modèle dépend des données, de l'interprétabilité et des contraintes (temps, mémoire).

Exemple de modèles avancés

Modèle	Famille	Usage typique
XGBoost, LightGBM, CatBoost	Boosting gradient	Tabulaire, compétitions
Réseaux profonds (CNN)	Deep Learning	Images, vision
RNN, LSTM	Deep Learning	Séquences, texte, séries temporelles
Transformers (BERT, GPT...)	Deep Learning	NLP, texte, multimodale
Réseaux à attention	Deep Learning	Vision, séries, graphes

Ces modèles demandent plus de données et de calcul ; ils excellent sur des tâches complexes (vision, langage, grands tableaux).

Exemple d'application 1 : Détection de spam


Contexte :

- Boîte mail recevant des **centaines de messages** par jour
- Objectif : classer chaque email en **spam** ou **legitimate** (ham)
- Règles manuelles (mots-clés) facilement contournées

Problème de classification binaire :

$$y = \begin{cases} 0 & \text{ham (valide)} \\ 1 & \text{spam} \end{cases}$$

Features : contenu du message (bag-of-words, TF-IDF), métadonnées (expéditeur, en-têtes), etc.



Exemple d'application 2 : Prédiction de churn client


Contexte :

- Entreprise (télécom, SaaS, assurance) avec une **base d'abonnés**
- Objectif : prédire quels clients sont susceptibles de **résilier** (churn)
- Permet de cibler des actions de rétention

Problème de classification binaire :

$$y = \begin{cases} 0 & \text{reste} \\ 1 & \text{part (churn)} \end{cases}$$

Features : historique d'usage, facturation, support, durée d'ancienneté, etc.



Pourquoi découper les données ? Un modèle doit **généraliser** à de nouvelles données, pas seulement mémoriser l'entraînement.

Rôle de l'ensemble train :

- Sur lequel le modèle **apprend** (optimise ses paramètres)
- `model.fit(X_train, y_train)`
- Utilisé pour estimer les statistiques de normalisation (moyenne, écart-type)
- Typiquement 70–80 % des données

Normalisation (Z-score) : $x'_j = (x_j - \mu_j) / \sigma_j$ — μ_j et σ_j calculés **sur le train uniquement**, puis appliqués au test.

Rôle de l'ensemble test :

- **Jamais** utilisé pendant l'apprentissage
- Sert uniquement à **évaluer** la performance en conditions réelles
- `model.predict(X_test)` puis comparer à `y_test`
- Simule des données « futures » inconnues du modèle
- Typiquement 20–30 % des données

Biais et variance : le compromis fondamental

Pour tout estimateur $\hat{f}$, l'erreur se décompose :

$$\underbrace{\mathbb{E}[(y - \hat{f}(x))^2]}_{\text{erreur totale}} = \underbrace{\text{Biais}^2}_{\text{sous-ajustement}} + \underbrace{\text{Variance}}_{\text{sur-ajustement}} + \sigma^2$$

Compromis :

- Modèle **trop simple** → biais élevé (underfitting)
- Modèle **trop complexe** → variance élevée (overfitting)

