

Chapitre 3 : Forêts Aléatoires (Random Forest)

Apprentissage Supervisé

Dr Seydou Nourou SYLLA

Université Alioune DIOP de Bambey
Master SI/SR

2 mars 2026

Plan du chapitre

- 1 Du biais/variance au bagging
- 2 Random Forest : l'ingrédient clé
- 3 Implémentation from scratch
- 4 Out-of-Bag et importance des features
- 5 Forces, faiblesses et hyperparamètres

Problème : variance élevée des arbres

Rappel : Un arbre profond a une **variance élevée**.

- Deux datasets légèrement différents $\rightarrow$ deux arbres très différents
- Sensible aux outliers et au bruit des données

Idée fondamentale : Si je combine plusieurs estimateurs bruités mais **non corrélés**, la variance **se réduit** !

Propriété statistique

Soient T estimateurs indépendants de même variance σ^2 . Leur moyenne a une variance de σ^2/T .

En pratique : Les arbres ne sont pas indépendants, mais la décorrélation les rend plus robustes.

$\Rightarrow$ Idée du Bagging : construire T arbres sur des données légèrement différentes, puis agréger.

Bagging (Bootstrap AGGREGatING)

Étape 1 – Bootstrap :


- Tirer n exemples **avec remise** depuis $\mathcal{D}_{train}$
- Chaque bootstrap $\mathcal{D}_t$ est légèrement différent
- $\approx 63\%$ des exemples uniques par bootstrap

Étape 2 – Construction :

- Construire un arbre **profond** sur $\mathcal{D}_t$
- Répéter T fois $\rightarrow T$ arbres différents

Étape 3 – Agrégation :

- Classification : **vote majoritaire**
- Régression : **moyenne**



De Bagging à Random Forest

Problème du bagging pur : Les arbres restent **corrélés** car ils utilisent souvent les mêmes features dominantes.

Innovation Random Forest (Breiman, 2001) :

Sous-échantillonnage aléatoire des features

À chaque nœud, au lieu de tester toutes les p features, on tire **aléatoirement** m features ($m \ll p$) et on choisit la meilleure parmi elles.

Effet :

- Les arbres sont **moins corrélés** entre eux
- La variance de l'ensemble diminue davantage
- Les features moins importantes ont une chance d'être utilisées

Valeurs typiques de m :

- Classification : $m = \sqrt{p}$
- Régression : $m = p/3$

Dans notre IDS ($p = 8$) : $m = \lfloor \sqrt{8} \rfloor = 2$
ou 3

Algorithme Random Forest – Pseudocode

Algorithme 1 : Random Forest

Input : $\mathcal{D}_{train}$, T (nb arbres), m (nb features/nœud), paramètres arbres

Output : Forêt $\mathcal{F} = \{f_1, \dots, f_T\}$

Entraînement ;

for $t = 1$ **to** T **do**

$\mathcal{D}_t \leftarrow \text{bootstrap}(\mathcal{D}_{train})$;

$f_t \leftarrow \text{BuildTree}(\mathcal{D}_t, m)$;

// tirage avec remise

// arbre avec m features/nœud

end

Prédiction pour un exemple x ;

foreach arbre $f_t \in \mathcal{F}$ **do**

$\hat{y}_t \leftarrow f_t(x)$;

end

if *Classification* **then**

return $\hat{y} = \text{mode}(\hat{y}_1, \dots, \hat{y}_T)$;

else

return $\hat{y} = \frac{1}{T} \sum_{t=1}^T \hat{y}_t$;

end

Rappel : Le bootstrap tire n exemples avec remise $\Rightarrow \approx 37\%$ des exemples **ne sont pas** dans $\mathcal{D}_t$.

Idée OOB : Pour chaque exemple i , utiliser uniquement les arbres pour lesquels i était *out-of-bag* (hors bootstrap).

Avantage :

- Estimation de l'erreur **sans dataset de validation séparé**
- Équivalent à une validation croisée leave-one-out
- Gratuit computationnellement !

Deux méthodes :

1. Importance par impureté (MDI) :

$$\text{Importance}(j) = \frac{1}{T} \sum_{t=1}^T \sum_{\text{nœuds } v \text{ utilisant } j} \frac{n_v}{n} \cdot \text{Gain}(v)$$

2. Importance par permutation (MDA) :

Forces et faiblesses de Random Forest

Forces :

- + Réduit l'overfitting (vs un seul arbre)
- + Robuste au bruit et aux valeurs aberrantes
- + Estime l'erreur OOB (pas besoin de val set)
- + Feature importance intégrée
- + Facilement parallélisable
- + Bonnes performances *out-of-the-box*

Faiblesses :

- Moins interprétable qu'un seul arbre
- Lent en prédiction (100 arbres)
- Consomme de la mémoire (stocke tous les arbres)
- Pas adapté aux données très sparses (texte)

Hyperparamètre	Valeur par défaut	Recommandé IDS
n_estimators	100	≥ 100
max_depth	None	10–20
max_features	sqrt	sqrt
min_samples_leaf	1	2–5

À retenir

- Random Forest = Bagging + **aléa sur les features** à chaque nœud
- Réduit la variance par décorrélation des arbres
- L'OOB donne une estimation gratuite de la performance
- Meilleur modèle du cours sur IDS en termes de robustesse

Modèle	Accuracy (test)	Interprétabilité	Vitesse
KNN ($k = 5$)	99.21%	Faible	Lente
Arbre ($d=10$)	99.63%	Élevée	Rapide
RF (T=100)	99.81%	Moyenne	Moyenne