

Chapitre 6 : Métriques d'Évaluation

Apprentissage Supervisé

Dr Seydou Nourou SYLLA

Université Alioune DIOP de Bambey
Master SI/SR

2 mars 2026

Plan du chapitre

- 1 Rôle des mesures de performance
- 2 Matrice de confusion
- 3 Métriques : Precision, Recall, F1
- 4 Courbe ROC et AUC
- 5 Ajustement du seuil de décision
- 6 Validation croisée
- 7 Comparaison des modèles
- 8 Choix du modèle en pratique

Pourquoi évaluer un modèle ?

- **Comparer** plusieurs modèles (KNN, arbre, forêt, régression logistique, MLP) pour choisir le meilleur
- **Détecter** le sur-apprentissage (bonne performance en entraînement, mauvaise en test)
- **Communiquer** les résultats (rapports, publications, décisions métier)
- **Ajuster** le modèle (seuil de décision, hyperparamètres) en fonction du coût des erreurs

Mesure de performance

Une **métrique** résume la qualité des prédictions du modèle sur des données (souvent un ensemble de test). Elle doit être adaptée au problème : classification binaire, classes déséquilibrées, coûts asymétriques (ex. détection d'intrusion).

L'accuracy (taux de bonnes réponses)

Définition : proportion d'exemples correctement classés.

$$\text{Accuracy} = \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total d'exemples}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Propriétés :

- Valeur entre 0 et 1 (souvent exprimée en %)
- Intuitive : « 95% d'accuracy » = 95% des prédictions sont bonnes
- **Utile quand les classes sont à peu près équilibrées** (autant de positifs que de négatifs)

Pourquoi l'accuracy ne suffit pas ?

Scénario IDS : 99% de connexions normales, 1% d'attaques.

Un modèle **stupide** qui prédit toujours "normal" :

$$\text{Accuracy} = \frac{99\,000}{100\,000} = 99\% \quad \text{mais détecte 0 attaque !}$$

Problème des classes déséquilibrées

L'accuracy est **trompeuse** quand les classes sont déséquilibrées. On a besoin de métriques qui tiennent compte de chaque type d'erreur séparément.

En sécurité réseau, les erreurs n'ont pas le même coût :

- **Faux négatif (FN)** : une attaque passe inaperçue $\Rightarrow$ **très grave**
- **Faux positif (FP)** : alerte sur une connexion normale $\Rightarrow$ gêne, coûteux mais acceptable

La matrice de confusion

Pour un problème binaire :

		Prédiction	
		$\hat{y} = 0$	$\hat{y} = 1$
Réel	$y = 0$	TN	FP
	$y = 1$	FN	TP

- **TP** : Vrai Positif (attaque détectée)
- **TN** : Vrai Négatif (normal classé normal)
- **FP** : Faux Positif (fausse alarme)
- **FN** : Faux Négatif (attaque manquée)

Exemple IDS (25 195 connexions test) :

	Préd. Normal	Préd. Attaque
Normal	12 580 (TN)	187 (FP)
Attaque	93 (FN)	12 335 (TP)

$$n = 25\,195, \text{ TP} + \text{TN} + \text{FP} + \text{FN} = 25\,195$$

Métriques dérivées de la matrice de confusion

Accuracy :

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN}$$

Précision (Precision) :

$$\text{Prec} = \frac{TP}{TP + FP}$$

Parmi les alarmes, combien sont vraies ?

Rappel (Recall / Sensibilité) :

$$\text{Rec} = \frac{TP}{TP + FN}$$

Parmi les attaques réelles, combien sont détectées ?

F1-Score :

$$F_1 = 2 \cdot \frac{\text{Prec} \times \text{Rec}}{\text{Prec} + \text{Rec}} = \frac{2 TP}{2 TP + FP + FN}$$

Compromis harmonique entre précision et rappel.

Spécificité :

$$\text{Spec} = \frac{TN}{TN + FP}$$

Parmi les normaux, combien sont classés normaux ?

IDS : Priorité au Recall !

Manquer une attaque (FN élevé) est plus grave que les fausses alarmes (FP élevé). On maximise le **Recall**.

Calcul sur notre exemple IDS

Rappel de la matrice de confusion du Random Forest (test) :

$$TP = 12\,335, \quad TN = 12\,580, \quad FP = 187, \quad FN = 93$$

Métrique	Formule	Valeur
Accuracy	$(12335 + 12580)/25195$	99.81%
Précision	$12335/(12335 + 187)$	98.51%
Recall	$12335/(12335 + 93)$	99.25%
Spécificité	$12580/(12580 + 187)$	98.54%
F1-Score	$2 \times 0.9851 \times 0.9925 / (0.9851 + 0.9925)$	98.88%

Lecture : Le modèle manque $93/(12335 + 93) = 0.75\%$ des attaques.

Dans un réseau avec 1 million de connexions/jour, cela représente $\approx 7\,500$ attaques non détectées !

Courbe ROC (Receiver Operating Characteristic)

Idée : Les modèles qui produisent des probabilités ($\hat{p}$) peuvent utiliser différents seuils de décision.

Pour chaque seuil $\tau \in [0, 1]$:


$$\hat{y} = 1[\hat{p} \geq \tau]$$

On calcule :

- $\text{TPR}(\tau) = \text{Recall} = \frac{TP}{TP+FN}$ (axe y)
- $\text{FPR}(\tau) = 1 - \text{Spec} = \frac{FP}{FP+TN}$ (axe x)

AUC (Area Under Curve) :

- $\text{AUC} = 1$: modèle parfait
- $\text{AUC} = 0.5$: aléatoire
- $\text{AUC} \geq 0.9$: très bon modèle




Ajuster le seuil – Compromis Précision/Rappel

Contexte IDS : On veut maximiser le Recall (ne pas manquer d'attaques).

Solution : Baisser le seuil τ de 0.5 à une valeur plus basse.

- Plus d'alertes générées (FP augmente)
- Moins d'attaques manquées (FN diminue)

Courbe Précision-Recall :



Pourquoi et rôle de la validation croisée

Pourquoi ne pas évaluer sur un seul split train/test ?

- Le résultat dépend du **tirage** : un autre split donne une autre métrique
- Risque de **sous-estimer** ou **surestimer** les performances (variance élevée)
- Peu de données : garder 20–30 % pour le test réduit encore la taille d'entraînement

Rôle de la validation croisée :

Objectif

Réutiliser les données pour obtenir une **estimation plus stable** des performances : chaque exemple sert à la fois à l'entraînement (dans certains folds) et au test (dans un fold), sur plusieurs découpages. On obtient plusieurs scores puis une **moyenne** (et un écart-type) plutôt qu'un seul nombre fragile.


Usages : comparer des modèles, choisir des hyperparamètres, estimer la généralisation avant déploiement.

Validation croisée – K-Fold

Problème : L'évaluation sur un seul split train/test dépend du hasard.

K-Fold Cross-Validation :

- ❶ Diviser $\mathcal{D}$ en K partitions (*folds*) de taille égale
- ❷ Pour $k = 1, \dots, K$:
 - Entraîner sur les $K - 1$ autres folds
 - Tester sur le fold k
 - Calculer la métrique m_k
- ❸ Moyenne et écart-type : $\bar{m} \pm \sigma_m$



Avantages :

- Utilise toutes les données pour l'évaluation
- Estimation plus fiable et moins biaisée

Problème avec les datasets déséquilibrés

Avec K -Fold standard, un fold peut se retrouver avec très peu (voire 0) d'exemples de la classe minoritaire.

Solution : Stratified K-Fold

- Chaque fold respecte la **distribution des classes** du dataset original
- Obligatoire pour les problèmes déséquilibrés

Tableau récapitulatif des performances IDS

Modèle	Accuracy	Précision	Recall	F1	AUC
KNN ($k = 5$)	99.21%	99.03%	99.38%	99.20%	0.992
Arbre ($d=10$)	99.63%	99.42%	99.84%	99.63%	0.997
Random Forest	99.81%	98.51%	99.25%	98.88%	0.998
Régr. Logistique	97.12%	96.85%	97.41%	97.13%	0.991
MLP	99.69%	99.45%	99.92%	99.69%	0.999

Analyse :

- **MLP** a le meilleur Recall (99.92%) $\Rightarrow$ manque le moins d'attaques
- **RF** est le plus robuste et le mieux équilibré
- La Régression Logistique est la moins performante mais la plus rapide et interprétable
- Le KNN sans optimisation reste compétitif ($> 99\%$)

Résumé des métriques – Quand utiliser quoi ?

Métrique	Quand l'utiliser	Exemple IDS
Accuracy	Classes équilibrées	Général
Précision	FP coûteux (spam filter)	Minimiser fausses alarmes
Recall	FN coûteux (IDS, médecin)	Minimiser attaques manquées
F1-Score	Équilibrer Prec/Recall	Évaluation générale IDS
AUC-ROC	Comparer des modèles	Classement des modèles
Courbe PR	Classes très déséquilibrées	IDS avec peu d'attaques

Règle d'or pour l'IDS

Maximiser le Recall (détecter toutes les attaques) tout en gardant une Précision acceptable (éviter la saturation des analystes).

Ajuster le seuil τ selon le budget d'investigation : si l'équipe sécurité peut traiter X alertes/jour, choisir τ tel que $FP \leq X$.

Récapitulatif général du cours

Modèle	Norm.	Interp.	Vitesse	Acc IDS	Paradigme
KNN	✓	Faible	Lent train, lent pred	99.2%	Similarité
Arbre décision	×	Élevée	Rapide/Rapide	99.6%	Règles
Random Forest	×	Moyenne	Moyen/Moyen	99.8%	Ensemble
Régr. Logistique	✓	Élevée	Rapide/Rapide	97.1%	Probabiliste
MLP	✓	Faible	Lent/Moyen	99.7%	Neurones

Message final

Aucun modèle n'est universellement meilleur (**No Free Lunch Theorem**). Le choix dépend des contraintes : interprétabilité, vitesse, taille des données, déséquilibre des classes, et des coûts d'erreur spécifiques au métier.