



Introduction Machine Learning

Dr Seydou Nourou SYLLA

Data Scientist Senior
Departement TIC
Universite Alioune Diop de Bambey

April 15, 2024



Overview

1. Prérequis

2. Définition des Concepts

2.1 Définitions

2.2 Paradigme

3. Modèles

4. Méthodes de Machine Learning

4.1 Les Approches

4.2 Questions

4.3 Les méthodes

Méthode supervisée

Méthode non supervisée

Méthode semi supervisée

Re-inforcement Learning



Prérequis

- **Informatique**

1. Algorithmique.
2. Complexité.
3. Programmation (impérative ou orientée objets.
4. Connaissance d'un environnement de développement intégré.
5. Sensibilisation aux problématiques de l'embarqué.
6. ...

- **Mathématiques / Statistique**

1. Statistique descriptive
2. Méthodes estimation
3. Algèbre linéaire
4. Optimisation
5. ...





Définition des Concepts

Machine Learning

Le ML est un élément constitutif de l'IA.

On apprend ainsi à la machine à effectuer des tâches

Deep Learning

le DL est une approche du ML.

Il simule le cerveau à travers des réseaux de neurones artificiels constitués de plusieurs couches entre les entrées et la sortie.

Définitions

Définition 1

Machine Learning (Apprentissage Automatique) consiste à concevoir des Modèles (algorithmes) qui extraient automatiquement des informations précieuses à partir de données.

Définition 2

Machine Learning est un processus de découverte de règle, relations, corrélations et/ou dépendances à travers une grande quantité de données, grâce à des méthodes statistiques, mathématiques et de reconnaissances de formes.

Définition 3

Machine Learning est un processus d'extractions automatique d'informations prédictives à partir de grandes bases de données.

Le **Data Science (Machine Learning)** est l'ensemble:

- Des **algorithmes** et **méthodes** destinés à
 - l'Exploration,
 - l'Analyse

de grandes bases de données informatiques

Permettant de détecter dans ces données des motifs ou modèles valides.

Ces algorithmes et modèles doivent pouvoir être généralisés à de nouvelles données:

- en offrant un avantage compétitif
- en synthétisant les données
- en contribuant à leur compréhension

Pour **l'aide à la décision**

Objectif

Nous concevons des modèles qui sont généralement liés au processus qui génère les données.

On dit d'un modèle qu'il apprend à partir de données si sa performance sur une tâche donnée s'améliore après la prise en compte des données.

Nouvel objectif

On ne cherche pas toujours un modèle mathématique optimal Mais le modèle le plus facile à appréhender

Objectif



L'objectif général est donc un objectif de modélisation qui peut se préciser en sous-objectifs à définir clairement préalablement à une étude car ceux-ci conditionnent en grande part les méthodes qui pourront être mises en oeuvre

Modéliser pour :

- explorer, vérifier, représenter, décrire, les variables, leurs liaisons et positionner les observations de l'échantillon,
- expliquer, tester l'influence d'une variable ou facteur dans un modèle supposé connu a priori,
- prévoir, sélectionner un meilleur ensemble de prédicteurs
- prévoir par une éventuelle meilleure "boîte noire" sans besoin d'interprétation explicite.



Paradigme de PTE

Machine Learning est l'étude des algorithmes qui :

- améliorent leurs performances P
- à une tâche T
- avec l'expérience E.

Définition Tom Mitchell (1998)

Trois concepts sont au cœur du Machine Learning :

1. Données
2. modèle / Apprentissage
3. Evaluation

Modèle

Le but est de trouver de bons modèles qui généralisent bien à des données encore inconnues, qui pourraient nous intéresser dans le futur.

Apprentissage

- L'apprentissage peut être compris comme une manière de trouver automatiquement des modèles et des structures dans les données en optimisant les paramètres du modèle.
- L'objectif de l'apprentissage est de trouver un modèle et les paramètres correspondants de façon à ce que le prédicteur résultant soit performant sur des données non vues.

Il existe conceptuellement trois phases algorithmiques distinctes en Machine Learning :

1. L'apprentissage ou l'estimation des paramètres
2. Prédiction ou inférence
3. Réglage des hyperparamètres ou sélection du modèle

La phase de prédiction est celle où nous utilisons un prédicteur entraîné sur des données de test qui n'ont pas encore été vues. auparavant.



Approche explicative

- On cherche à découvrir les variables ou les associations de variables, les variables les plus pertinentes pour décrire les différences entre groupes a priori et à déterminer si ces différences sont significatives.



Approche décisionnelle

- On cherche à affecter tout nouvel individu ou objet à des groupes définis a priori. La méthode proposée doit s'adapter à la diversité des données comme l'abondance, la rareté des individus ou objets, le nombre de descripteurs et le nombre de classes.




Questions

- **Les choix de méthodes, de modèles**, sont complexes à opérer et se déclinent en sous-objectifs qui restreignent où précisent les classes de modèles à considérer.
- **L'objectif est-il seulement prédictif ?** Sous-entendu, un modèle boîte noire suffit-il à répondre aux besoins sans interprétation détaillée ?
- **une compréhension du modèle**, donc de l'impact des variables, attributs ou facteurs, est-elle recherchée voire indispensable ? Ou, plus précisément, est-ce la détermination d'un petit sous-ensemble de ces variables

Méthode supervisée : Type de Données

En apprentissage supervisé, les données dites annotées de leurs sorties pour entraîner le modèle, c'est-à-dire que chaque entrée est déjà associée un label ou une classe cible.

Elle s'applique à des populations décrites par des variables et munies d'une partition définie a priori et d'un intérêt particulier.





Méthode supervisée : Modèle

Objectif

L'objectif est de construire, à partir de cet échantillon d'apprentissage, un modèle, qui va nous permettre de prévoir la sortie Y associée à une nouvelle entrée (ou prédictor) X .

L'objectif est que l'algorithme devienne capable, une fois entraîné, de prédire cette cible sur de nouvelles données non annotées.



Méthode supervisée : Apprentissage

- La classification supervisée construit directement la règle de décision à partir des données observées.
- Elle vise à séparer au mieux les classes de la partition à l'aide des variables explicatives.

Méthode supervisée : Types de modèles

Le modèle à appliquer dépend fortement du type de la variable de sortie Y :

- Quantitative (prix d'un stock, consommation électrique, carte de pollution ..)
- Qualitative (survenue d'un cancer, reconnaissance de chiffres...)

Il dépend aussi de la nature et de l'espace des variables X

- ensemble de cardinal fini
- réelles
- fonctionnelles.



Méthode supervisée : Types de modèles

- Si Y est **qualitative / Catégorielle**, on parle de discrimination, classement ou reconnaissance de forme
- Si Y est **quantitative** on parle, "par habitude", d'un problème de régression.

Remarques

Certaines méthodes s'adaptent à tout type de variables explicatives tandis que d'autres sont spécialisées.


Méthode supervisée : Mesure d'évaluation



Voir Chapitre : Méthode supervisée

Méthode non supervisée : Donnée

les données d'entrées ne sont pas annotées.






Méthode non supervisée : Objectifs


- Algorithme s'applique dans ce cas à trouver seul les similarités et distinctions au sein de ces données, et à regrouper ensemble celles qui partagent des caractéristiques communes
- La classification non supervisée dite aussi clustering permet de modéliser le système qui a généré les données observées et à partir de cette modélisation construit la règle de décision.
- Elle cherche une typologie ou segmentation c'est-à-dire une partition ou une répartition des individus en classes ou groupes.
- Le classement se fait en optimisant un critère permettant de regrouper les individus dans des classes les plus homogènes et les plus distinctes possible.
- Le nombre de partitions n'est pas souvent connu a priori.

Méthode semi supervisée

Entre les apprentissages supervisé et non supervisé, se situe un autre type d'apprentissage. Il s'agit de l'apprentissage semi-supervisé ou on l'on dispose d'une partie de données annotées et d'une autre partie de données non annotées



Il s'agit d'un type d'apprentissage que l'on utilise dans une situation où on a besoin de prendre des mesures/actions et planifier dans un environnement spécifique. Ex: Jeux, Feu de circulation etc.



Merci