
Examen Pratique : Pipeline Complet de Machine Learning

UAD - Bambey

Master I : SI-SR

Contexte du Projet

Vous travaillez en tant que Data Scientist pour un consortium hospitalier (Projet type **FedMedDiag**). Votre objectif est de construire un modèle de classification robuste capable de diagnostiquer une pathologie à partir de données tabulaires.

PARTIE 1 : Analyse Exploratoire et Baselines

1. Calculez le ratio des classes. Quel est le risque si l'on utilise l'**Accuracy** comme seule métrique ?
2. Identifiez les valeurs manquantes et les valeurs aberrantes (outliers).
3. Via une matrice de corrélation ou des boxplots, déterminez quelles variables semblent avoir le plus fort pouvoir discriminant.
4. Réalisez un split Train/Test (25% test).
5. Appliquez une imputation médiane pour les valeurs manquantes.
6. Entraînez “ modèles "baselines" (ex: Logistic Regression, Decision Tree, Random Forest, un modèle de votre choix).

PARTIE 2 : Robustesse et Généralisation

1. Comparez et interprétez les performances en variant le `train_size` de 0.3 à 0.7 avec un pas de 0.1 .
2. Trouver des méthodes pour régler le problème constaté
3. Appliquez cette méthode sur vos modèles baselines.
4. Que constatez-vous sur la variance des scores ? Lequel des modèles est le plus stable ?

PARTIE 3 : Optimisation des modèles

1. Changer les paramètres des modèles et afficher les résultats. Que constatez-vous?
2. Trouver des méthodes pour régler le problème constaté
3. Pour votre meilleur modèle baseline, appliquer la méthode trouvée pour avoir la combinaison optimale.
4. Comparez le modèle optimisé au modèle baseline. Le gain de performance justifie-t-il le temps de calcul ?

PARTIE 4 : Gestion du Déséquilibre

1. En affichant la matrice de confusion, que remarquez-vous sur les Faux Négatifs ? Pourquoi est-ce critique dans ce contexte ?
2. Implémentez et comparez les trois approches suivantes :
 - SMOTE (Oversampling synthétique).
 - ADASYN (Oversampling adaptatif).
 - SMOTE + Tomek Links (Combinaison d'over et undersampling).
3. Quel impact ces méthodes ont-elles sur la Précision et le Rappel de la classe positive ?

PARTIE 5 : Méthodes d'Ensemble

Pour maximiser les performances, combinez vos modèles optimisés.

1. Testez les approches suivantes :
 - Voting Classifier (Hard & Soft).
 - Stacking (Utilisez une Régression Logistique comme méta-classifieur).
2. Remplissez un tableau récapitulatif :
 - *Meilleur F1-Score* | *Meilleure Précision* | *Meilleur Rappel*.
3. Si vous devez déployer ce modèle en milieu hospitalier, privilégiez-vous la Précision ou le Rappel ? Pourquoi ?

PARTIE 6 : Industrialisation

1. Créez un objet Pipeline de Scikit-Learn regroupant : l'imputation, le scaling, le resampling (via imblearn.pipeline) et le modèle final.
2. Utilisez la bibliothèque joblib ou pickle pour enregistrer votre pipeline entraîné ainsi que les résultats de performance.

PARTIE 7 : Déploiement

L'objectif final est de rendre votre modèle accessible aux cliniciens via une interface intuitive.

1. Concevez une micro-application web (via Streamlit, Flask ou FastAPI) permettant de saisir les paramètres médicaux d'un patient.
2. Chargez votre pipeline final (modèle enregistré) pour générer et afficher instantanément la probabilité de la pathologie.
3. Implémentez une fonctionnalité de journalisation (logging) permettant d'enregistrer chaque consultation (caractéristiques saisies et prédiction associée) dans une base de données (SQLite, PostgreSQL ou un fichier structuré).