
UNIVERSITÉ ALIOUNE DIOP DE BAMBEY

MASTER 1 — SI / SR

Traitement et analyse de données | Introduction en IA

Atelier complet : de la donnée au modèle

Année universitaire 2025 – 2026

Professeur : Dr Seydou Nourou SYLLA

Consignes générales

- Objectif : résoudre une tâche de **classification**.
- **Niveau de difficulté du pré-traitement (identique pour les trois jeux)** : chaque fichier contient les mêmes *familles* d'imperfections (valeurs manquantes, formats mixtes avec virgules ou unités, catégories hétérogènes, doublons, valeurs aberrantes ponctuelles). Le travail de nettoyage et de codage est volontairement **comparable** d'un projet à l'autre.
- Livrables obligatoires :
 - un fichier Python de code structuré et bien documenté,
 - un modèle sauvegardé (format `.pkl`, `.joblib` ou équivalent),
 - une application web de démonstration avec modèle déployé.
- Pipeline minimal attendu :
 1. Exploration et analyse des données (EDA),
 2. Pré-traitement complet,
 3. Modélisation (au moins 3 algorithmes),
 4. Optimisation des hyperparamètres de chaque modèle,
 5. Évaluation et interprétation,
 6. Sélection et sauvegarde du meilleur modèle,
 7. Déployer une application web (Streamlit, Flask, FastAPI + front simple) qui :
 - enregistre les variables en entrée de chaque utilisateur dans une base de données,
 - affiche la probabilité de fraude et la classe prédite,
 - journalise les prédictions dans la base de données.

Projet 1 — Détection de fraude sur transactions e-commerce

Contexte. Une plateforme de commerce en ligne souhaite détecter les transactions frauduleuses en temps quasi réel afin de réduire les pertes financières et les litiges clients.

Jeu de données fourni.

- Fichier : `projet1_fraude_transactions.csv`

- Taille : 1800 individus
- Variables : 20 variables explicatives + 1 variable cible
- Cible : **fraude** (0 = transaction légitime, 1 = transaction frauduleuse)

Question de synthèse. Quelle stratégie de détection recommandez-vous en production pour minimiser les faux négatifs de fraude sans multiplier excessivement les faux positifs ?

Projet 2 — Prédiction de l'attrition clients (churn) télécom

Contexte. Un opérateur télécom veut anticiper le départ des clients afin de cibler les actions de rétention et réduire le taux de churn.

Jeu de données fourni.

- Fichier : `projet2_attrition_clients.csv`
- Taille : 1800 individus
- Variables : 20 variables explicatives + 1 variable cible
- Cible : **attrition** (0 = client conservé, 1 = client en risque de départ)

Question de synthèse. Quels sont les 3 leviers métier prioritaires que vous recommanderiez à l'opérateur à partir des résultats du modèle ?

Projet 3 — Prédiction de complications médicales à 6 mois

Contexte. Un centre hospitalier veut identifier précocement les patients à risque de complication dans les 6 mois suivant une hospitalisation, afin d'adapter le suivi clinique.

Jeu de données fourni.

- Fichier : `projet3_sante_complications.csv`
- Taille : 1880 individus
- Variables : 20 variables explicatives + 1 variable cible
- Cible : **complication_6m** (0 = pas de complication, 1 = complication)

Question de synthèse. Quelles variables sont les plus actionnables pour réduire le risque de complication et quelles limites éthiques doit-on considérer pour ce type de modèle en santé ?

Évaluation

- Qualité du pré-traitement et justification méthodologique : 25 %
- Pertinence des modèles et optimisation des hyperparamètres : 25 %
- Rigueur de l'évaluation et interprétation : 20 %
- Qualité du déploiement web (ergonomie + robustesse) : 20 %
- Qualité du fichier : 10 %