

Exercice Pratique

TAD, Master SI- SR

Dr Seydou Nourou SYLLA – Département TIC – Université Alioune Diop de Bambey

9 février 2026

Consignes : Les données doivent être bien nettoyées et prêtes pour la modélisation. Le rapport doit être bien structuré et bien documenté.

1 Phase 1 – Chargement et analyse exploratoire (EDA)

1.1 Partie 1 : Analyse des données

1. Charger le fichier CSV . Vérifier le nombre de lignes et de colonnes.
2. Afficher une description des données pour chaque type de variable (quantitative, qualitative, object)
3. Convertir `admission_date` en type `datetime`.
4. Créer une dictionnaire de données qui décrit le nom de la variable, du type et de la description
5. Calculer le nombre et le pourcentage de valeurs manquantes par colonne.
6. Rappeler brièvement la différence entre MCAR, MAR et MNAR. Associer chaque variable à manquants à un mécanisme.
7. Pour `weight_kg`, vérifier si les manquants sont plus fréquents chez les patients de plus de 65 ans.

1.2 Partie 2 : Statistiques descriptives et visualisations univariées

8. Pour les variables **quantitatives** : calculer moyenne, médiane, écart-type, Q_1 , Q_3 , IQR. Commenter la symétrie et la présence potentielle d'outliers.
9. Tracer un **histogramme** et un **boxplot** pour `age` et `length_of_stay`. Identifier visuellement les valeurs aberrantes.
10. Pour les variables **catégorielles** : calculer les effectifs et les fréquences relatives. Tracer un diagramme en barres pour `region`.
11. Calculer la matrice de corrélation de Pearson sur les colonnes numériques. Afficher une **heatmap** (seaborn).
12. Identifier au moins deux paires de variables fortement corrélées. Donner la valeur de r et interpréter.
13. Tracer le nuage de points pour une de ces paires. Commenter.

2 Phase 2 – Preprocessing

2.1 Détection et gestion des doublons

14. Détecter les lignes dupliquées sur l'ensemble des colonnes. Combien y en a-t-il ?

15. Détecter les doublons sur `patient_id` uniquement : combien de `patient_id` apparaissent plus d'une fois ?
16. Choisir une stratégie de gestion des doublons et l'appliquer. Justifier votre choix.

2.2 Gestion des valeurs manquantes

17. Pour `glucose_fasting` (MCAR) : imputer par la **médiane**. Vérifier qu'il ne reste plus de manquants.
18. Pour `weight_kg` (MAR) : imputer par la **moyenne par tranche d'âge** (ex. 18–40, 41–65, 66+).
19. Pour `stress_level` (MNAR) : discuter brièvement du biais possible si on impute. Ajouter éventuellement un **flag stress_level_missing** (1 si manquant, 0 sinon).
20. Traiter les manquants restants par une méthode de votre choix. Documenter.

2.3 Détection et traitement des valeurs aberrantes

21. Appliquer la **règle IQR** sur `age`, `length_of_stay`, `weight_kg`, `bmi`, `creatinine`. Pour chaque variable, donner le nombre d'outliers détectés et les bornes $[Q_1 - 1,5 \times \text{IQR}, Q_3 + 1,5 \times \text{IQR}]$.
22. Choisir **une** variable (ex. `age`) : remplacer les valeurs hors IQR par la médiane.
23. Appliquer le **z-score** sur une variable et comparer les outliers avec la règle IQR.

2.4 Encodage des variables catégorielles

24. Lister toutes les variables catégorielles (nominales et ordinales).
25. Pour chaque type de variable : appliquer un encodage approprié. Nommer les nouvelles colonnes de façon lisible.
26. Vérifier que toutes les variables utilisables pour la modélisation sont numériques ou encodées. Sauvegarder une version **encodée** du jeu.

2.5 Normalisation / standardisation

27. Justifier pourquoi une mise à l'échelle est nécessaire.
28. Sur le sous-ensemble des **variables numériques continues**, appliquer une méthode de normalisation/standardisation.
29. Vérifier que la transformation est correcte.

3 Phase 3 – Feature engineering

3.1 Variables dérivées

30. Créer `bmi_derived = weight_kg / (height_cm/100)2`. Comparer avec la colonne `bmi`.
31. Créer `pulse_pressure = sys_bp - dia_bp` (pression pulsée).
32. Créer le ratio `ldl_hdl_ratio = cholesterol_ldl / cholesterol_hdl`. Gérer les valeurs nulles ou infinies si nécessaire.

3.2 Variables temporelles

33. À partir de `admission_date`, créer : `admission_day_of_week`, `admission_month`, `admission_weekend`.

3.3 Binnage

34. Créer `age_group` : tranches 18–30, 31–50, 51–65, 66+ (ou 4 tranches de votre choix).
35. Créer `bmi_category` : Sous-poids ($< 18,5$), Normal (18,5–25), Surpoids (25–30), Obésité (> 30).
36. Vérifier que les variables créées sont utilisables pour la modélisation.

4 Phase 4 – Réduction de dimension

4.1 Sélection de variables (filtre)

37. Sur le jeu nettoyé et encodé (variables numériques uniquement), appliquer `VarianceThreshold` avec un seuil adapté (ex. 0,01 ou 0,1) pour éliminer les variables quasi constantes. Combien de variables restent-elles ?
38. Calculer la **corrélation** de chaque variable numérique avec la cible `readmission_30d`. Garder les 10–15 variables les plus corrélées (en valeur absolue). Lister les variables sélectionnées.
39. Expliquer la méthode de sélection des variables et les critères utilisés.

4.2 PCA

40. Sur les variables numériques continues (standardisées), appliquer les étapes d'une **PCA**.
41. Combien de composantes permettent d'expliquer 95 % de la variance ?
42. Afficher le **scree plot** (variance expliquée par composante) et la **variance expliquée cumulée**. Interpréter en 2–3 phrases.
43. Projeter les données sur les 2 premières composantes et tracer un nuage de points coloré par `readmission_30d`. Commenter la séparation des classes.

4.3 Rapport

44. Rédiger un **paragraphe de synthèse** (une demi-page) décrivant : (1) les problèmes de qualité initiaux (doublons, manquants, outliers), (2) les traitements appliqués, (3) les variables créées (feature engineering), (4) le résultat de la réduction de dimension (nombre de composantes PCA ou variables sélectionnées).

4.4 Export

45. Exporter le jeu de données **nettoyé et prêt pour la modélisation**.
46. Exporter aussi les données réduites.