



Chapitre 5

L'extraction de fragments : XPath, XQuery



Introduction

- Comme son nom l'indique, XPath est une spécification fondée sur l'utilisation de chemin d'accès permettant de se déplacer au sein du document XML.
- Dans ce but, un certain nombre de fonctions ont été définies. Elles permettent de traiter les chaînes de caractères, les booléens et les nombres.



Introduction

- XPath est un langage avec une syntaxe non XML, permettant d'adresser les différents noeuds ou groupes de noeuds particuliers d'un document XML.
- XPath voit le document XML comme un arbre de noeuds, qu'il permet de parcourir selon des axes (fils, parent, ancêtre, descendant, ...) et en sélectionnant les noeuds par leur nom.
- Les expressions XPath permettent également de représenter des chaînes de caractères, des nombres et des booléens.

Introduction

- XPath permet d'**effectuer des requêtes** dans un document XML.
- XPath est aux documents XML, ce qu'est SQL aux bases de données.
- XPath est **utilisé par XSLT** pour faire de la transformation de documents XML.

Chemin de localisation

- Un chemin de localisation peut être de type absolu ou relatif.
 - Dans le cas où il est de type **absolu**, il commence toujours par le signe / indiquant la racine du document XML ;
 - Dans le cas où il est de type **relatif**, le noeud de départ est le noeud contextuel courant.

Chemin de localisation

- Un chemin de localisation est composé de **trois parties** :
 - un **axe**, définissant le sens de la relation entre le noeud courant et le jeu de noeuds à localiser;
 - un **noeud** spécifiant le type de noeud à localiser;
 - 0 à n **prédicats** permettant d'affiner la recherche sur le jeu de noeuds à récupérer.

Chemin de localisation

- Par exemple, dans le chemin `child::section[position()=1]`,
 - `child` est le nom de l'axe,
 - `section` le type de noeud à localiser (élément ou attribut)
 - `[position()=1]` est un prédicat.
- Les doubles `::` sont obligatoires.
- La syntaxe d'une localisation s'analyse de gauche à droite.
- Dans notre cas, on cherche dans le noeud courant, un noeud section qui est le premier noeud de son type.

Axes

- **child** : contient les enfants directs du noeud contextuel.
- **descendant** : contient les descendants du nœud contextuel. Un descendant peut être un enfant, un petitenfant...

Axes

- **parent** : contient le parent du noeud contextuel, s'il y en a un.
- **ancestor** : contient les ancêtres du noeud contextuel. Cela comprend son père, le père de son père... Cet axe contient toujours le noeud racine, excepté dans le cas où le noeud contextuel serait lui-même le noeud racine.



Axes

- **following-sibling** : contient tous les noeuds frères qui suivent le noeud contextuel. Dans le cas où ce noeud est un attribut ou un espace de noms, la cible suivante est vide.
- **preceding-sibling** : contient tous les frères prédécesseurs du noeud contextuel ; si le noeud contextuel est un attribut ou un espace de noms, la cible précédente est vide.


Axes

- **following** : contient tous les noeuds du même document que le noeud contextuel qui sont après le noeud contextuel dans l'ordre du document, à l'exclusion de tout descendant, des attributs et des espaces de noms.
- **preceding** : contient tous les prédécesseurs du noeud contextuel ; si le noeud contextuel est un attribut ou un espace de noms, la cible précédente est vide.

Axes Axes



Axes



Axes

- **attribute** : contient les attributs du noeud contextuel ; l'axe est vide quand le noeud n'est pas un élément.
- **namespace** : contient tous les noeuds des espaces de noms du noeud contextuel ; l'axe est vide quand le noeud contextuel n'est pas un élément.
- **self** : contient seulement le noeud contextuel.
- **descendant-or-self** : contient le noeud contextuel et ses descendants.
- **ancestor-or-self** : contient le noeud contextuel et ses ancêtres. Cet axe contiendra toujours le noeud racine

Prédicats

- Un prédicat **mis entre crochets** permet encore de restreindre l'ensemble des nœuds sélectionnés.
- Les prédicats peuvent combiner avec les opérateurs **or** et **and** plusieurs conditions qui peuvent faire intervenir des fonctions prédéfinies.

Exemples

- **child::text ou text**
 - élément text fils d'un nœud du contexte.
- **/child::text ou /text**
 - élément text sous la racine c'est-à-dire contenant tout le document
- **attribute::text ou @text**
 - attribut text d'un nœud du contexte

Exemples

- **child::chapter/child::section** ou **chapter/section**
 - élément section fils d'un nœud chapter lui-même fils d'un nœud du contexte.
- **parent::node()/child::chapter** ou **../chapter**
 - élément chapter frère d'un nœud du contexte.
 -
- **self::node()/descendant-or-self::section** ou **../section**
 - élément section descendant d'un nœud du contexte.

Exemples

- **child::section[position()=2]** ou **section[2]**
 - deuxième élément section fils du nœud courant.
- **descendant::p/following-sibling::em[position()=1]**
ou **//p/following-sibling::em[1]**
 - premier frère em d'un élément p descendant du nœud courant.
- **child::section[child::title]** ou **section[title]**
 - élément section fils du nœud courant et ayant un fils title.

Exemples

- **child::section[attribute::title]** ou **section[@title]**
 - élément section fils du nœud courant et ayant un attribut title.
- **child::section[attribute::title='Un titre']** ou **section[@title='Un titre']**
 - élément section fils du nœud courant et ayant un attribut title égal à la chaîne Un titre.

Exemples

- **chapter[count(child::section) > 1]**
 - élément chapter ayant plus d'un élément section comme fils.
- **@*[name() != 'id']**
 - attributs autres que l'attribut id.
- **section[2][@type='dual']**
 - deuxième élément section du nœud courant si son attribut type vaut dual.

XQuery

- XQuery est un langage de puissant pour extraire des données XML
- Type de données: un seul "document" ou encore des collections sous forme de:
 - fichiers
 - bases de données XML
 - XML "en mémoire" (abres DOM)

XQuery

- Ex: Une requête qui permet très simplement de renvoyer tous les noeuds **auteur** du document biblio.xml.
 - Aucune mise en forme n'étant pratiquée, les nœuds renvoyés le sont avec leurs balises et leur contenu telqu'il s'exprime dans le document.
 - **document("biblio.xml")//auteur**

Les expressions FLWOR

- FLWR = "For-Let-Where-Order-Return"
-
- rappelle l'idée du select-from-where-..-order-by de SQL

Document Exemple

• <bibliothèque>

- <livre année="2002">
 - <titre> Prélude à fondation </titre>
 - <auteur><nom> Asimov </nom><prénom> Isaac </prénom></auteur>
 - <éditeur> Pocket </éditeur>
 - <prix>6</prix>
- </livre>
- <livre année="1995">
 - <titre> La marche des millénaires </titre>
 - <auteur><nom> Asimov </nom><prénom> Isaac </prénom></auteur>
 - <auteur><nom> White </nom><prénom> Frank </prénom></auteur>
 - <éditeur> Flammarion </éditeur>
 - <prix>8.45</prix>
- </livre>
- <livre année="2005">
 - <titre> Avant Dune </titre>
 - <auteur><nom> Anderson </nom>
 - <prénom> Kevin J. </prénom></auteur>
 - <auteur><nom> Herbert </nom><prénom> Brian </prénom></auteur>
 - <éditeur> Pocket </éditeur>
 - <prix>12.3</prix>
- </livre>

• </bibliothèque>

Les expressions FLWOR

- **for** = itération sur une liste de fragments xml
- **let** = association du résultat d'une expression à une variable
- **where** = condition de sélection
- **order** = tri des résultats
- **return** = expression à retourner

"for"

- **for \$variable in expression_recherche
RETURN**
- "for" associe à chaque \$variable une valeur (fragment XML) trouvé pour l'expression XQuery
- Exemple:
- **for \$t in
document("biblio.xml")//livre**

let

- **"let"** permet d'assigner une valeur à une variable
- requête qui permet d'affecter la variable **\$b** successivement avec le contenu des noeuds **livre** du document biblio.xml (clause **for**) et d'affecter à **\$a** l'ensemble des nœuds **auteur** contenus dans chaque itération de **\$b** (clause **let**).
- **for \$b in document("biblio.xml")//livre**
- **let \$a := \$b/auteur**
- **return <livre nb_auteurs="{count(\$a)}"> { \$a } </livre>**

where

- permet de définir une condition de sélection
- requête pour extraire le **titre** des livres dont le premier noeud fils **auteur** contient comme valeur de **nom** Mansour.
- **for \$a in document("biblio.xml")//livre**
- **where \$a/auteur[1]/nom eq "Mansour"**
- **return \$a/titre**

order

- permet de trier les résultats
- requête pour extraire le **titre** des livres dont le premier noeud fils **auteur** contient comme valeur de **nom** Mansour.
- **for \$a in document("biblio.xml")//livre**
- **where \$a/auteur[1]/nom eq "Mansour"**
Order by \$a
- **return \$a/titre**

Exemple avec jointure (avec EditiX)

- **Draft de DTD**
- `<!ELEMENT base (etudiant | class)*>`
- `<!ELEMENT etudiant (nom, prenom, adresse)>`
- `<!ELEMENT class (nom)>`
- `<!ATTLIST etudiant identifiant ID classe IDREF>`
- `<!ATTLIST class ident ID>`
- **Nom et prénom des étudiant qui sont en WEB2 (nom classe)**

```
<?xml version="1.0" encoding="UTF-8"?>
<liste>
  <etudiant>
    <nom>KARE</nom>
    <prenom>Massamba</prenom>
  </etudiant>
  <etudiant>
    <nom>DIALLO</nom>
    <prenom>Ndiogou</prenom>
  </etudiant>
</liste>
```

`<liste>`

- for \$a in /base/etudiant
- for \$b in /base/class
- where (\$a/@classe=\$b/@ident and \$b/nom='WEB2')
- return
- `<etudiant>{$a/nom, $a/prenom}`
- `</etudiant>`
- }

`</liste>`



FIN